

Metricas del modelo de distribucion de especies (SDM), explicadas

Este documento explica, en lenguaje sencillo, las metricas con las que evaluamos nuestro modelo de distribucion de especies (SDM, por sus siglas en ingles: Species Distribution Model). El objetivo es que cualquier persona, sin necesidad de ser especialista, entienda que medimos, que significa un "buen" resultado y como le fue a nuestro modelo.

Dicho rapido, un SDM aprende en que condiciones ambientales (clima, suelo, relieve) vive una especie y, con eso, dibuja un mapa de "donde es probable encontrarla". Las metricas son las notas del examen de ese mapa.

Resumen ejecutivo

Estos son los resultados promedio de nuestro modelo sobre 14 especies, medidos con validacion cruzada espacial (la forma realista de evaluar, explicada mas abajo).

Todos los numeros son **media entre folds** de la validacion cruzada espacial (13 especies; la forma sin maquillar de medir transferencia, explicada mas abajo).

Metrica	Que mide en una frase	Rango	Umbral "bueno"	Nuestro modelo
TSS	Aciertos balanceando presencias y ausencias	-1 a 1	> 0.5 aceptable, > 0.7 bueno	0.26 (flojo)
AUC	Capacidad de ordenar sitios buenos por encima de malos	0.5 a 1	> 0.8 bueno	0.77 (aceptable)
Boyce / CBI	Si las zonas mas idoneas concentran mas presencias reales	-1 a 1	cercano a 1	0.44 (mixto)
Brier	Error de las probabilidades (calibracion)	0 a 1	cuanto menor mejor	0.04*
MESS	Donde el modelo extrapola (predice fuera de lo que vio)	mapa	—	mapa diagnostico

En resumen: el modelo **ordena** sitios de forma aceptable (AUC 0.77), pero su acierto balanceado transfiriendo a zonas nuevas es flojo (TSS 0.26, con mucha variabilidad entre subregiones), y la coherencia solo-presencia (Boyce 0.44) es **mixta**, buena en 4–6 especies y mala o negativa en 4. El *Brier* (0.04) parece excelente pero **engaña**: es bajo porque casi todo el territorio es "ausencia" y predecir valores bajos en todas partes ya da poco error. La calibracion real (slope ≈ 0) es pobre, asi que los numeros son **idoneidad relativa, no probabilidades**.

Ninguna metrica se reporta sola; mas adelante explicamos por que.

Una analogia para todo el documento

Imagine que el modelo es un explorador que nunca vio la especie, pero estudio miles de fotos del paisaje donde si vive. Le pedimos que, mirando un terreno nuevo, diga: "aqui es muy probable encontrarla" o "aqui no".

- **TSS** mide cuantas veces acierta en sus dos tipos de juicio: detectar donde si esta y descartar donde no esta.
- **AUC** mide si, cuando comparamos dos sitios, sabe poner mas arriba al que de verdad tiene la especie.
- **Boyce** mide si los lugares que el explorador marca como "los mejores" son, en efecto, donde mas veces se ha visto la especie.
- **Brier** mide si cuando dice "80% de probabilidad", de verdad acierta el 80% de las veces (no que sea timido ni que sea fanfarron).
- **MESS** es el explorador admitiendo: "este paisaje no se parece a nada de lo que estudie; aqui mi opinion vale menos".

Las metricas, una por una

TSS (True Skill Statistic)

- **Que mide:** los aciertos del modelo, pero de forma balanceada. Premia por igual detectar bien las presencias (donde si esta la especie) y las ausencias (donde no esta). Esto evita que un modelo "tramposo" que dice "no esta en ningun lado" parezca bueno solo porque las ausencias son mayoria.
- **Analogia:** una nota de examen que cuenta por igual las dos preguntas ("donde si" y "donde no"), en vez de dejar que una sola domine.
- **Rango:** de -1 a 1. Un 0 equivale a adivinar al azar; valores negativos serian peor que el azar.
- **Que valor es bueno:** mayor a 0.5 es aceptable; mayor a 0.7 es bueno.
- **Nuestro modelo:** media por fold de **0.26**, un valor flojo y con SD alta (varía mucho

entre subregiones de Chile). Antes se reportaba 0.707, pero ese número usaba un umbral elegido mirando las propias respuestas del examen (optimizado sobre los datos de evaluación), lo que infla el TSS. Ya corregido, el 0.26 es la transferencia espacial real.

AUC (area bajo la curva ROC)

- **Que mide:** la probabilidad de que, si tomamos al azar un sitio con presencia

y otro sin ella, el modelo le asigne una puntuación más alta al que sí tiene la especie. Es decir, mide su capacidad de **ordenar** correctamente.

- **Analogía:** un juez que, entre dos candidatos, casi siempre identifica al

correcto, aunque no acierte el porcentaje exacto.

- **Rango:** de 0.5 (azar puro) a 1 (perfecto).
- **Que valor es bueno:** mayor a 0.8 es bueno; mayor a 0.9 es excelente.
- **Nuestro modelo:** media **por fold** de **0.77** (aceptable). El AUC "pooled"

(juntando todos los folds) sube a 0.89, pero ese pooling mezcla regiones y sobrestima; el 0.77 por fold es el que refleja la realidad.

- **Nota importante:** con background planetario (iteraciones anteriores) el AUC

llegaba a 0.944. Ese número era artificialmente alto: si la especie vive solo en Chile, distinguir su clima del de un desierto antártico o un polo es trivialmente fácil y el AUC sube sin que eso pruebe mucho. Al acotar el background a Chile, el modelo debe discriminar entre sitios climáticamente similares dentro del país, y el AUC cae a 0.77 (por fold): un valor más realista y más informativo. Por eso el background regional es metodológicamente correcto para especies endémicas. Y por eso nunca reportamos el AUC solo: lo acompañamos de TSS, de Boyce y de validación espacial.

Boyce / CBI (Continuous Boyce Index)

- **Que mide:** si las zonas que el modelo marca como **mas idoneas** son,

efectivamente, donde se concentran más presencias reales. Es la métrica más fiable cuando solo tenemos datos de **presencia** (como los de GBIF, la base de datos global de observaciones), porque no requiere saber con certeza donde la especie está ausente, dato que casi nunca tenemos.

- **Analogía:** marcamos en un mapa las "zonas premium" según el modelo y luego

contamos cuántos avistamientos reales caen ahí. Si las zonas premium concentran muchas más observaciones que las zonas pobres, el modelo es coherente.

- **Rango:** de -1 a 1. Cercano a 1 es bueno (las zonas idoneas concentran las

presencias); cercano a 0 significa que el modelo no separa mejor que el azar; y **negativo es malo**: las presencias aparecen justo donde el modelo decía que no deberían estar.

- **Que valor es bueno**: cuanto mas cerca de 1, mejor.
- **Nuestro modelo**: media de **0.44**, pero ese promedio esconde mucha

dispersión: 4 especies tienen Boyce ≥ 0.77 (confiables), 4 están entre 0.36 y 0.59 (buenas) y 4 están en 0.2 o por debajo, dos de ellas negativas (senna -0.66 , pleurophora $-0.23 \rightarrow$ el modelo pone las presencias justo donde dice que no deberían). Es la metrica mas fiable para datos solo-presencia y la que mas peso tiene: aquí es la que delata que el modelo NO sirve para varias especies.

Brier score

- **Que mide**: que tan buenas son las **probabilidades** que da el modelo, no

solo si acierta el si/no. Es una medida de **calibracion**: cuando dice "70% de probabilidad", queremos que de verdad ocurra cerca del 70% de las veces.

- **Analogia**: un pronosticador del tiempo. No basta con acertar si llueve o no;

si dice "90% de lluvia", debe llover casi siempre que lo dice. Un Brier bajo es un pronosticador en quien se puede confiar al pie de la letra.

- **Rango**: de 0 a 1. **Menor es mejor**; 0 seria perfecto.
- **Nuestro modelo**: media de **0.04**, pero **cuidado, este número engaña**. El Brier

sale bajo porque la especie está ausente en casi todo el territorio: un modelo que predice "idoneidad baja" en todas partes ya acierta la mayoría de las celdas y obtiene Brier bajo sin mérito real. La calibración de verdad (la pendiente de la curva de calibración) es ≈ 0 en casi todas las especies, lo que significa que los números **no** son probabilidades confiables. Trátales como un **índice de idoneidad relativa**: "este sitio es más apto que aquel", no "hay 80% de probabilidad".

MESS (Multivariate Environmental Similarity Surface) - extrapolacion

- **Que mide**: mas que una nota de acierto, es un **mapa de confianza**. Senala

las zonas donde el modelo esta prediciendo en condiciones ambientales que **nunca vio al entrenar** (por ejemplo, temperaturas o lluvias fuera del rango conocido). En esas zonas el modelo esta extrapolando y su prediccion es **menos confiable**.

- **Analogia**: el explorador del ejemplo diciendo "este paisaje no se parece a

nada de lo que estudie". Su opinion sigue ahi, pero con una advertencia.

- **Como se usa**: acompaña a los mapas de idoneidad para marcar las regiones

donde hay que tomar la prediccion con cautela. Es especialmente util para proyecciones a escenarios futuros de clima, donde la extrapolacion es inevitable.

Validacion cruzada espacial: por que es la clave de todo

Para confiar en una nota, el examen tiene que ser justo. En modelos de distribucion de especies, el examen justo es la **validacion cruzada espacial**.

Que es: dividimos el area de estudio (Chile y sus presencias) en **bloques geograficos** y entrenamos el modelo ocultandole un bloque completo. Luego lo evaluamos justamente en ese bloque que **no vio**. Repetimos rotando los bloques. Asi medimos si el modelo realmente **transfiere** su conocimiento a zonas nuevas dentro del pais, que es lo que de verdad nos interesa.

Por que importa (y por que NO usamos puntos al azar): los puntos que estan geograficamente cerca se parecen mucho entre si (clima, suelo y relieve casi identicos). Si repartimos los puntos al azar (un k-fold aleatorio comun), es casi seguro que un punto de "examen" tenga un vecino practicamente igual en el grupo de "estudio". El modelo entonces no demuestra que aprendio, sino que **memorizo al vecino de al lado**. El resultado: notas artificialmente altas que se desploman en el mundo real.

Bandera roja, no verde: por eso, una metrica de 0.99 obtenida con k-fold aleatorio no es una buena noticia, sino una **senal de alarma** (probable fuga de informacion y sobreajuste). Un AUC 0.77 sin inflar por fold con validacion espacial y background regional vale mucho mas que un 0.99 inflado con background global. Todos los numeros de este documento provienen de validacion espacial por fold.

Forma de evaluar	Que tan parecidos son examen y estudio	Que mide en realidad	Veredicto
K-fold aleatorio	Muy parecidos (puntos vecinos mezclados)	Memorizacion del vecino	Infla resultados; enganoso
Validacion cruzada espacial	Distintos (regiones separadas)	Capacidad real de transferir	Honesto; el que usamos

Como leer un caso bueno frente a uno problematico

Las metricas se entienden mejor con ejemplos reales de nuestras especies. Los valores a continuacion son ilustrativos del marco regional (iteracion 3, background acotado a Chile).

Caso bueno: Encelia canescens

Metrica	Valor (iter. 2, background global)	Lectura
TSS	0.95	Acierta presencias y ausencias casi siempre
AUC	0.99	Ordena casi a la perfeccion sitios buenos sobre malos
Boyce	0.97	Las zonas idoneas concentran de forma muy clara las presencias reales

Nota: estos valores corresponden a la iteracion 2 con background global. Con background regional (Chile, iteracion 3) es esperable que TSS y AUC sean menores porque el problema de discriminacion es mas dificil; un AUC cercano a 0.99 con background planetario era en parte trivial para una endemica cuyo clima no se parece al de ningun polo o desierto remoto.

Las tres metricas altas **a la vez** siguen siendo la senal de una especie bien aprendida: el modelo captura su patron y lo transfiere a zonas nuevas dentro de Chile y Sudamerica.

Caso problematico: Schinus areira

Metrica	Valor (iter. 2, background global)	Lectura
Boyce	-0.31	Negativo: las presencias caen donde el modelo decia que no deberian

Aqui el Boyce es **negativo**, una senal de problema. La causa no es un error de programacion, sino la biologia: Schinus areira es una **especie introducida**. Vive en sitios a los que el ser humano la llevo, no necesariamente donde su clima "natural" lo predeciria, y su patron **no transfiere bien entre zonas** (lo que aprende el modelo en una zona no sirve en otra). Con el marco regional (Chile, iteracion 3) la especie tiene n=72 registros en Chile, suficiente para modelar, pero la interpretacion sigue siendo la misma: el mapa refleja nicho climatico dentro del area calibrada, no invasividad. Es un ejemplo perfecto de por que miramos varias metricas y por que la validacion espacial es tan reveladora: un caso asi pasaria desapercibido con un k-fold aleatorio, pero una evaluacion sin maquillar lo deja en evidencia y nos dice "cuidado con interpretar este mapa al pie de la letra".

La leccion para el lector no especialista: un numero malo no siempre significa "modelo mal hecho"; a veces significa "esta especie es dificil por su biologia", y detectarlo es justamente parte del valor del analisis.

Por que ninguna metrica sola basta

Cada metrica mira una cara distinta del problema y tiene un punto ciego. Por eso reportamos un conjunto: donde una falla, otra avisa.

Que reportamos	Que pregunta responde	Por que no basta sola
TSS	Acierta el si/no de forma balanceada?	No dice nada sobre que tan buenas son las probabilidades ni sobre el ordenamiento fino
AUC	Ordena bien los sitios buenos sobre los malos?	Con background planetario se infla para endemias; con background regional (Chile) el valor es mas realista pero sigue sin bastar solo
Boyce / CBI	Las zonas idoneas concentran las presencias reales?	Es la mas honesta con solo-presencia, pero es ruidosa y puede ser exigente; conviene leerla junto a las demas
Brier	Las probabilidades estan bien calibradas?	Mide calidad del numero, no la capacidad de separar presencia de ausencia
MESS	Donde la prediccion es menos confiable?	No es una nota de acierto; solo marca zonas de extrapolacion
Validacion espacial	El modelo transfiere a territorio nuevo?	Es el metodo de prueba, no una metrica; da sentido honesto a todas las anteriores

Miradas en conjunto, estas metricas dan una vision completa y sin inflar, y esa vision sin maquillar no es triunfalista. Nuestro modelo (iteracion 3, background regional Chile, métricas por fold) **ordena** sitios de forma aceptable (AUC 0.77) pero su transferencia espacial es floja (TSS 0.26, muy variable entre subregiones); la coherencia solo-presencia es **mixta** (Boyce 0.44, confiable en 4–6 especies, malo o negativo en 4), y las salidas son **idoneidad relativa, no probabilidades** (el Brier 0.04 engaña por la baja prevalencia). El MESS marca dónde leer con cautela. Para decidir, lo útil es leer especie por especie (tabla en `informe_modelo.md`) y no quedarse con el promedio: hay 4 especies confiables, varias solo indicativas y 4 cuyo mapa no debe usarse.