

Proceso de trabajo completo — Iteración 2 (bitácora detallada)

Este documento narra, paso a paso, todo el trabajo de la iteración 2: qué se encontró mal, cómo se diagnosticó, qué se corrigió, qué experimentos se hicieron y por qué se tomó cada decisión. Objetivo: que cualquier persona entienda el proceso completo y pueda auditarlo o reproducirlo.

Resultado final en una línea: se pasó de **12 de 14 especies con métricas rotas (NaN)** a **14 de 14 validables**, con un ensemble que **iguala a MaxEnt** (TSS 0.82, AUC 0.94) y aporta robustez e incertidumbre.

0. Punto de partida (iteración 1)

- 14 especies modelables (grupos A y B), 13.354 → 4.566 ocurrencias GBIF tras

limpieza (deduplicación, incertidumbre, máscara de océano, thinning espacial).

- Ensemble de 5 algoritmos (GLM, GAM, RF, GBM, MaxEnt), ponderado por TSS, con

validación cruzada por bloques espaciales globales de 750 km.

- Aparentemente "funcionaba": el reporte de iteración 1 mostraba AUC de 0.95–1.00

para casi todas las especies. Eso fue, precisamente, la primera señal de alarma.

1. Auditoría: cuatro fallos de raíz

1.1 Pendiente (slope) corrupta

Al inspeccionar los datos extraídos, la pendiente tenía **mediana 89.8 grados y el 99% de los puntos por encima de 80 grados**: el modelo "creía" que casi toda la Tierra es un acantilado vertical, lo cual es físicamente imposible.

Causa: `xrspatial.slope()` asume coordenadas en metros (CRS proyectado), pero la grilla está en grados (EPSG:4326) y la elevación en metros. El gradiente dz/dx sale gigantesco (metros por grado) y `atan(gigante) ≈ 90°`. La variable entró como predictor en 9 de 14 modelos: ruido casi constante.

1.2 Background (pseudo-ausencias) sesgado a los polos

45% de los puntos de background caían en zonas polares/glaciales (Antártida, Ártico, Siberia), y 28.5% tenían temperatura media anual por debajo de -20 grados. Ninguna de estas especies árido-templadas podría registrarse ahí.

Causa: el "target-group background" aplicaba un suavizado de Laplace (`effort[land] += 1.0`) sobre TODA la tierra. Con millones de celdas y solo ~4.566 registros reales, el suavizado aplastaba la señal de esfuerzo de muestreo y el background terminaba prácticamente

uniforme sobre la tierra; como los polos son una fracción enorme de la superficie, quedaban sobre-representados.

Efecto en los modelos: separar el nicho de una especie de un background dominado por la Antártida es trivial. De ahí salían las **AUC infladas de 0.95–1.00** que el documento de diseño ya marcaba como bandera roja.

1.3 Validación cruzada espacial degenerada (el fallo más grave)

La grilla global fija de 750 km repartía las presencias de una endémica de rango estrecho en **1 o 2 bloques**, es decir 1–2 folds. Los otros 3–4 folds quedaban sin presencias, se saltaban por completo, y los puntos de esos folds nunca recibían una predicción out-of-fold (OOF). Esos NaN rompían todas las métricas basadas en sklearn (AUC, AUC-PR, Brier, calibración), que quedaban en NaN silenciosamente.

Evidencia medida (presencias por fold con presencia):

Especie	folds con presencia (de 5)	% NaN en OOF
atriplex_semibaccata (cosmopolita)	5	0%
schinus_areira (cosmopolita)	5	0%
encelia_canescens	4	19.5%
eulychnia_acida	1 (las 150 presencias en un fold)	81.1%
nolana_divaricata	2	62.3%

Por eso solo las 2 especies cosmopolitas (presencias repartidas por el mundo) tenían métricas completas; las 12 endémicas estaban rotas.

1.4 Combinación del ensemble y otros

La ponderación por TSS y el fallback de “pesos iguales” enmascaraban fallos; además había fuga de datos en el escalado (StandardScaler ajustado sobre todos los datos antes del CV) y una normalización OOF frágil.

2. Correcciones de datos

2.1 Pendiente

Recalculada con el algoritmo de Horn (1981) convirtiendo el tamaño de celda de grados a metros con escala dependiente de la latitud: $m_por_grado_lon = 111320 \cdot \cos(lat)$. Verificación: **mediana 89.8 → 0.21 grados, 0% por encima de 80 grados, máximos realistas en zonas montañosas**. Corregido en tres lugares: los datasets (fix_slope_base_datos.py), el código fuente (03_terrain.py) y el raster global (regenerar_slope_tif.py → slope.tif).

2.2 Background

Poda del background no-hábitat (`quemar_background_inservible.py`) con criterio ligado a los datos (ninguna presencia lo viola): se eliminó el background con $\text{bio1} < -5$ o $|\text{lat}| > 55$ o $\text{bio4} == 0$. Resultado: **270.500 → 132.835 puntos (-51%)**, rango de latitud del background de -89.9/+83.6 a -55/+55, y **0 puntos con $\text{bio1} < -20$** . Las presencias (registros GBIF reales) no se tocaron.

2.3 Verificación de calidad de predictores

- 0 NaN en predictores y coordenadas.
- Rangos físicos correctos (temperaturas, precipitación, elevación).
- Consistencia interna $\text{bio7} = \text{bio5} - \text{bio6}$ exacta.
- 0 precipitaciones negativas; orden de temperaturas $\text{bio5} \geq \text{bio6}$ correcto.

3. Corrección de la validación cruzada (lo que rescató a las endémicas)

Se reemplazó la grilla global por **CV espacial adaptativo (leave-one-spatial- cluster-out)**: las presencias se agrupan con k-means en 5 clústeres espaciales (longitud corregida por $\cos(\text{lat})$); cada clúster es un fold; el background se asigna al fold del centroide de presencias más cercano. El tamaño de fold se adapta al rango de cada especie (continental para cosmopolitas, subregional para endémicas), garantizando que **cada fold contenga presencias**.

Verificación: las 14 especies pasaron a tener **5 folds con presencias** (antes: eulychnia 1, krameria/nolana 2, etc.) y **0 de 14 con métricas NaN** (antes 12/14).

Mejoras de calidad asociadas: escalado ajustado dentro de cada fold (sin fuga de datos) y normalización OOF por fila (robusta).

4. Tuning de hiperparámetros (3 agentes en paralelo)

Cada algoritmo se tuneó con búsqueda aleatoria (~20 configuraciones) evaluada con el CV espacial, optimizando solo sobre las especies con CV válido (para no ajustar contra ruido). Ganancias en TSS de CV:

Algoritmo	Config ganadora	TSS antes → después
GLM	C=0.5, L1,	0.725 → 0.756
GAM	class_weight=balanced	
	n_splines=25, lam=10	0.803 → 0.813
RF	n_estimators=300,	0.787 → 0.819
	max_depth=30,	
	min_samples_leaf=8,	
	max_features=log2,	
	balanced_subsample	
GBM	n_estimators=800,	0.809 → 0.816
	min_child_samples=20,	
	reg_lambda=1, subsample=0.7,	
	colsample_bytree=0.9	
MaxEnt	features	0.791 → 0.796
	lineal+cuadrático+producto,	
	beta=1.59, tau=0.55,	
	class_weights=100	

5. Cómo combinar el ensemble (experimento clave)

Pregunta: ¿cómo combinar los 5 modelos para obtener el mejor ensemble? Se compararon cuatro estrategias, evaluadas sobre las predicciones OOF con el CV espacial (TSS al umbral maxTSS, anidado leave-one-fold-out donde aplica):

Estrategia	TSS medio	Veredicto
Ponderación por TSS ³	0.73	concentraba demasiado, descartada
Stacking (meta-modelo logístico)	0.77	sobreajuste con pocas presencias, descartada
Promedio simple (todos)	0.81	bueno
Promedio equal-weight (excluye modelos con TSS<0.5)	0.82	elegida

Hallazgo importante: la ponderación TSS³ que se había introducido antes en realidad **empeoraba** el ensemble (lo bajaba a 0.73). El promedio equal-weight de los modelos que superan el umbral es la mejor combinación y la más simple.

Además se corrigió un sesgo en la comparación: el TSS del ensemble se calculaba con el umbral de training mientras que el de cada algoritmo usaba el umbral óptimo sobre OOF. Se unificó (ambos al umbral maxTSS sobre OOF) para que la comparación ensemble vs MaxEnt sea justa.

Corrección posterior (revisión 3.1): unificar "al umbral óptimo sobre OOF" fue un error — optimizar el umbral sobre el propio conjunto de evaluación infla el TSS. Se revirtió: el TSS del ensemble se reporta al umbral de **entrenamiento**, y el encabezado pasó a ser el **TSS por fold (media ± SD)**. Con eso, el TSS medio honesto es 0.26, no 0.82/0.707, y el ensemble deja de "superar" a MaxEnt.

6. Resultado final (CV espacial, ensemble equal-weight)

Media: TSS 0.82 · AUC 0.94 · Boyce 0.68 · Brier 0.04. Las 14 especies con métricas completas.

Especie	n	TSS	AUC	Boyce
miqueliopuntia_miquelii	129	0.98	0.99	0.78
skytanthus_acutus	84	0.98	0.99	0.65
encelia_canescens	271	0.95	0.99	0.97
krameria_cistoidea	223	0.94	0.99	0.90
nolana_divaricata	45	0.93	0.99	0.69
oxalis_gigantea	68	0.88	0.97	0.69
nolana_sedifolia	37	0.85	0.95	0.67
eulychnia_acida	150	0.81	0.97	0.81
cumulopuntia_sphaerica	135	0.79	0.95	0.93
senna_cumingii	92	0.78	0.95	0.74
atriplex_semibaccata	1054	0.77	0.95	0.88
neltuma_chilensis	184	0.69	0.87	0.94
schinus_areira	1309	0.62	0.84	−0.31
pleurophora_pungens	56	0.54	0.81	0.16

Comparación con MaxEnt (misma vara para ambos)

	Ensemble	MaxEnt
TSS medio	0.822	0.826
AUC medio	0.944	0.939
Ensemble $\geq$ MaxEnt (TSS)	8 / 14	—

El ensemble **igual a MaxEnt** (diferencia de TSS 0.004, dentro del ruido), lo supera levemente en AUC, y le gana en 8 de 14 especies. Su valor diferencial no es un TSS más alto sino **robustez** (no depende de un solo algoritmo) e **incertidumbre** (acuerdo entre los 5 modelos por píxel).

7. Lectura honesta y limitaciones

- 12 de 14 especies son sólidas/buenas bajo validación espacial estricta.
- **schinus_areira** es la excepción: es una especie introducida y su Boyce

negativo indica que no transfiere bien entre regiones (su distribución la marca la historia de invasión, no solo el clima). No usar su mapa para predecir invasividad sin un marco específico.

- **Pendientes declarados:** forecast a 2050 (CMIP6) no ejecutado ni validado (no

presentar proyecciones de cambio climático todavía); sin validación por hindcasting; el sampler de background sigue siendo global en origen (se saneó por poda); 3 especies truncadas en el techo de descarga de GBIF (3.000 registros).

8. Orden de los scripts (reproducibilidad)

1. 01_limpieza.py — limpieza de ocurrencias.
2. 02_capas_presente.py — descarga/preparación de capas WorldClim presentes.
3. 03_terrain.py — derivación de terreno (pendiente Horn geográfico) y alineación.
4. 04_extraccion.py — extracción de predictores, background, CV espacial adaptativo.
5. 05_modelado.py — ensemble (lee tuned_params/), combinación equal-weight.
6. 06_validacion.py — métricas (TSS/AUC/Boyce/Brier/MESS, comparación justa).
7. 07b_present_suitability.py — mapas de idoneidad presente.
8. 08_mapas.py — figuras PNG.

Utilidades de saneamiento de esta iteración: fix_slope_base_datos.py, quemar_background_inservible.py, regenerar_slope_tif.py, aplicar_cv_adaptativo.py.

Iteración 3 — Acotar a Chile (área de calibración) y mapa a Sudamérica

Diagnóstico: AUC inflados por extensión planetaria del background

Las métricas de iteración 2 seguían en AUC 0.95–0.99. La poda polar del background (sección 2.2) había eliminado el síntoma más obvio, pero el problema de raíz permanecía intacto: el background cubría **todo el planeta**, y las 14 especies son endémicas o cuasi-endémicas chilenas. Separar el nicho climático de una planta del desierto chileno de "el resto del mundo" es una tarea trivial para cualquier clasificador; el AUC alto no refleja capacidad discriminativa real sino la enormidad del contraste geográfico.

Evidencia concreta — skytanthus_acutus:

Presencias: lon [-71, -70] lat [-36, -24] (franja andina chilena)
Background: lon [-164, 179] lat [-55, 55] (el planeta entero)

Con ese contraste, incluso un modelo nulo que usara solo longitud obtendría AUC > 0.95.

Solución: edición quirúrgica del área, sin tocar el resto del pipeline

Se modificaron cuatro archivos. El resto del pipeline (limpieza, capas, terreno, modelado, validación) no se tocó.

config.py

Se añadieron dos parámetros de área:

- CALIBRATION_COUNTRY = "Chile" — nombre para la máscara de tierra.
- CALIBRATION_BBOX — bounding box del Chile continental.
- PREDICTION_BBOX — bounding box de Sudamérica (para proyecciones y mapas).

04_extraccion.py

Nuevo helper `_load_calibration_mask` que intersecta la capa de tierra (Natural Earth admin-0, ya cacheada por `01_limpieza.py`) con el polígono de Chile y, de respaldo, con el `CALIBRATION_BBOX`. Efectos:

1. El **background se muestrea solo dentro de Chile**: las celdas fuera del polígono

no son elegibles, independientemente de sus valores climáticos.

1. Las **presencias también se recortan a Chile**: esto es relevante para las

introducidas *Schinus areira* y *Atriplex semibaccata*, cuyos registros GBIF son globales; dentro de este proyecto interesa modelar solo la fracción chilena.

07_forecast_2050.py y 07b_present_suitability.py

`build_predictor_stack` acepta ahora el parámetro `extent_bbox` y recorta el stack al `PREDICTION_BBOX` antes de predecir. La proyección de idoneidad presente cubre **Sudamérica** en lugar del planeta entero (~0.9 M píxeles vs decenas de millones): más rápido y más informativo visualmente.

08_mapas.py

La vista por defecto de los mapas se enfoca en Sudamérica. Antes llamaba a `ax.set_global()`, lo que forzaba una vista mundial centrada en el Atlántico que hacía los mapas de Chile prácticamente ilegibles.

Verificación de la máscara de Chile

```
Celdas en la máscara : 49.807
Rango de longitud    : [-75.6, -67.0]
Rango de latitud     : [-55.6, -17.6]
Fraccion de la tierra: 0.4 %
```

El recorte es el Chile continental exacto (excluye la Antártida chilena).

Resultados: métricas honestas tras acotar el área

Las métricas **bajaron** respecto a iteración 2. Eso es la señal correcta: antes estaban infladas por el contraste geográfico trivial; ahora el modelo tiene que discriminar dentro del territorio donde las especies realmente viven.

Medias (CV espacial): (*iter. 3 = numeros honestos por fold, revision 3.1*)

Metrica	Iteracion 2 (global)	Iteracion 3 (Chile, por fold)
AUC	0.944	0.77
TSS	0.822	0.26
Boyce	0.68	0.44

Nota 3.1: el TSS 0.707 que figuraba aqui era el pooled con umbral optimizado sobre OOF (inflado). Corregido a 0.26 (media por fold, transferencia espacial real). atriplex (n=8) se excluye del modelado.

Por especie (iteracion 3, por fold + Boyce; 13 especies):

Especie	AUC fold	TSS fold	Boyce	Nota
krameria_cistoidea	0.71	0.10	+0.89	confiable (transfer local inestable)
skytanthus_acutus	0.80	0.35	+0.79	confiable
nolana_sedifolia	0.76	0.38	+0.79	confiable
nolana_divaricata	0.74	0.10	+0.77	confiable (transfer local inestable)
oxalis_gigantea	0.83	0.56	+0.59	buena
eulychnia_acida	0.79	0.49	+0.59	buena
miqueliopuntia_miquelii	0.84	0.12	+0.49	buena (transfer debil)
encelia_canescens	0.74	0.28	+0.36	aceptable
neltuma_chilensis	0.75	0.31	+0.19	floja
cumulopuntia_sphaerica	0.68	0.11	+0.15	floja
pleurophora_pungens	0.79	0.00	-0.23	no transfiere
senna_cumingii	0.76	0.27	-0.66	no transfiere
schinus_areira	0.81	0.26	+0.98	introducida, n bajo → Boyce artefactual

Las especies introducidas (*Atriplex semibaccata*, *Schinus areira*) colapsaron por datos: al recortar los registros GBIF globales a Chile, *atriplex_semibaccata* quedó con solo **n = 8 presencias** en Chile, por debajo del umbral operativo de 50 registros. *Schinus areira* bajó a **n = 72**, suficiente para modelar pero con transferencia geográfica muy limitada dentro del país.

Las especies que quedan expuestas como flojas (cumulopuntia, neltuma, pleurophora, senna) no son errores del pipeline: son especies con poca señal climática dentro del dominio chileno, lo cual es una conclusión ecológica relevante en sí misma.

8. Orden de los scripts (reproducibilidad) — actualización iteración 3

- 01_limpieza.py — limpieza de ocurrencias (también cachea polígono Natural Earth).
- 02_capas_presente.py — descarga/preparación de capas WorldClim presentes.
- 03_terrain.py — derivación de terreno (pendiente Horn geográfico) y alineación.
- 04_extraccion.py — extracción de predictores; **acota background y presencias a Chile** mediante `_load_calibration_mask`; CV espacial adaptativo.

5. 05_modelado.py — ensemble (lee tuned_params/), combinación equal-weight.
6. 06_validacion.py — metricas (TSS/AUC/Boyce/Brier/MESS, comparacion justa).
7. 07b_present_suitability.py — idoneidad presente **recortada a Sudamerica** (PREDICTION_BBOX).
8. 08_mapas.py — figuras PNG con **vista centrada en Sudamerica** (no global).

Utilidades de saneamiento de iteracion 2 (siguen siendo validas): fix_slope_base_datos.py, quemar_background_inservible.py, regenerar_slope_tif.py, aplicar_cv_adaptativo.py.