

Resultados — Iteración 1

NOTA: documento superado por la iteración 2. Esta iteración 1 tenía tres fallos que se corrigieron después: pendiente (slope) errónea ($\sim 90^\circ$ en casi todo el planeta), $\sim 45\%$ del background en zonas polares y CV espacial degenerado para endémicas (métricas NaN). Los resultados vigentes están en `informe_modelo.md`. Se conserva este archivo como registro.

Este es el resumen de la primera iteración del pipeline SDM (`global-flora-sdm`): modelos ensemble entrenados, validación con CV espacial e idoneidad del presente. El forecast a 2050 queda diferido como mejora (ver §"Trabajo futuro").

Datos

- **Ocurrencias GBIF:** 13.354 $\rightarrow$ **4.566** tras la limpieza (dedup, incertidumbre, máscara de océano, thinning espacial a $2.5'$). Quedan 14 especies modelables (grupos A/B).
- **Predictoras:** 10 bioclim WorldClim v2.1 más 4 topográficas (elevación, pendiente, northness, eastness), alineadas a $2.5'$ (~ 5 km) global.
- **Background:** 20.000 puntos (target-group). La selección de predictores se hizo por correlación ($|r| > 0.7$) y VIF (> 10). CV espacial en bloques de 750 km.

Validación (CV espacial leave-one-block-out)

Especie	Presencias	TSS (media±sd)	AUC	Boyce	Veredicto
<i>Miqueliopuntia miquelii</i>	129	0.86 ± 0.14	0.99	0.68	sólido
<i>Schinus areira</i>	1309	0.74 ± 0.26	0.98	0.98	sólido
<i>Encelia canescens</i>	271	0.72 ± 0.34	1.00	0.85	sólido
<i>Atriplex semibaccata</i>	1054	0.71 ± 0.11	0.98	0.79	sólido
<i>Oxalis gigantea</i>	68	0.54 ± 0.10	0.97	0.78	bueno
<i>Nolana sedifolia</i>	37	0.53 ± 0.47	0.92	0.08	variable
<i>Cumulopuntia sphaerica</i>	135	0.46 ± 0.44	0.86	0.93	variable
<i>Senna cumingii</i>	92	0.44 ± 0.30	0.98	0.32	moderado
<i>Nolana divaricata</i>	45	0.38 ± 0.12	1.00	0.57	moderado
<i>Pleurophora pungens</i>	56	0.33 ± 0.07	0.84	0.77	moderado
<i>Neltuma chilensis</i>	184	0.08 ± 0.06	0.91	0.43	débil
<i>Krameria cistoidea</i>	223	≈ 0.00	0.75	−0.75	degenerado
<i>Eulychnia acida</i>	150	0.00	0.07	—	degenerado
<i>Skytanthus acutus</i>	84	0.00	0.54	—	degenerado

Tabla completa (TSS/AUC/AUC-PR/F1/Brier/Boyce/OR10/MESS por algoritmo y ensemble):
 outputs/tables/metrics_all.csv.

Lectura de los resultados

- Hay 10 especies con modelos de moderados a sólidos, aptas para inferir idoneidad.
- Las 3-4 endémicas degeneradas (*Krameria*, *Eulychnia*, *Skytanthus*) no fallan por falta

de datos (tienen 84-223 presencias) sino por la geometría del CV espacial: sus presencias caen en 1-2 bloques de 750 km, y el leave-one-block-out deja fuera todo su rango, lo que colapsa el TSS. Es la tensión esperada entre un CV espacial estricto y endémicas de rango estrecho (ver docs/proyecto_sdm.md, nota 7).

- Una SD alta entre folds (p. ej. *Nolana sedifolia* 0.53±0.47) indica mala transferencia

entre regiones, algo coherente con la naturaleza endémica.

Salidas de la iteración

- `outputs/maps/{slug}_present_suitability.tif`: idoneidad del presente (0–1), 14 sp.
- `outputs/figures/{slug}_present.png`: mapas con overlay de ocurrencias (Etapa 8).
- `outputs/tables/metrics_*.csv`: métricas de validación.
- `data/modeling/ensemble_models/{slug}.joblib`: modelos ensemble reutilizables.

Trabajo futuro (prioridad)

1. Bloque CV adaptativo por especie (~250-350 km para endémicas de rango estrecho)

para repartir presencias en ≥ 3 folds y rescatar los modelos degenerados sin más datos.

1. Forecast 2050 (diferido). Está implementado en `07_forecast_2050.py`: descarga y

proyecta las 8 capas CMIP6 (ACCESS-CM2/IPSL/MPI/MRI $\times$ ssp245/ssp585). Queda pendiente optimizar el MESS global (es el cuello de botella; ya está vectorizado con `searchsorted`, falta procesarlo por bloques/submuestreo para que escale a 37M píxeles).

1. Relleno de borde costero en terreno (rellenar NaN de tierra con 0 antes de

enmascarar) para recuperar presencias costeras (p. ej. *N. sedifolia* 77→37).

1. Modelo regional para las endémicas chilenas, con pooling de congéneres *Nolana*.
2. Re-descarga GBIF particionada para las especies truncadas en 3.000 registros.