

Flujo de trabajo — Versión 4 (reconstrucción modular)

Propósito. Inventario de **los pasos que ejecuta cada script**, en el orden real del código. Esta es la unidad sobre la que iremos trabajando: **cada paso es algo que podemos mantener, modificar o eliminar** al reconstruir de forma modular. Misma lógica y mismo modelo que la iteración 3.1, con dos cambios de fondo: **alcance Sudamérica** (no solo Chile) y **estructura modular**.

- **Rama:** version-4
- **Dataset original (única fuente de verdad):** gbif_distribucion_especies.xlsx

(hoja Registros GBIF) — 13.354 registros, 21 especies, 15 columnas.

Leyenda de cada paso:

- (sin marca) = se mantiene igual que en 3.1.
- **V4** = paso que cambia en esta versión.
- **NUEVO** = paso que no existe en 3.1 y se agrega.
- = decisión de auditoría pendiente (tú decides antes de tocar código).

Estado: Etapa 01 lista para implementar; 02–08 inventariadas para auditar en orden.

Secuencia y artefactos (resumen)

```
xlsx → [01] → ocurrencias_limpias.gpkg → [04] → species_datasets/*.parquet → [05] → ensemble_models/*.joblib
      [02] → worldclim_present/ → [03] → rasters_aligned/
                                     |
                                     → [06] → tables/metrics_*.csv
                                     → [07b] → maps/*_present.tif → [08] → figures/*.png
                                     → [07] → forecast 2050 (DIFERIDO)
```

[01] 01_limpieza.py — limpieza de ocurrencias

Entrada: gbif_distribucion_especies.xlsx (hoja Registros GBIF) · **Salida:** data/processed/ocurrencias_limpias.gpkg (capa ocurrencias, EPSG:4326). Pasos en el orden real de main():

#	Paso (función)	Qué hace	V4
0	construir_geodataframe	Carga el xlsx (utils. load_raw_occurrences), renombra columnas a snake_case, descarta lat/lon nulas, crea geometría Point EPSG:4326.	
1	eliminar_duplicados	dedup exacto por (especie, lat, lon), conserva el primero.	
2	filtrar_incertidumbre	descarta incertidumbre_m > 10.000 m; los NaN se conservan.	
3	filtrar_coords_sospechosas	elimina NaN, (0,0), fuera de rango (lat >90/ lon >180) y coords con lat y lon de decimal .0 (truncadas).	
3b	'filtrar_sudamerica'	conserva solo registros dentro de Sudamérica (13.354 → ~8.498). Se inserta aquí, antes de los pasos caros.	NUEVO
4	filtrar_centroides_admin	descarta puntos a ≤ 1 km de centroides de país/provincia (Natural Earth admin-0/1). Paso más caro.	
5	filtrar_oceano	descarta puntos fuera de la land mask (Natural Earth), sjoin within.	
6	thinning_espacial	1 punto por celda 2.5' (1/24°) por especie; prefiere menor incertidumbre. (El paso que más reduce el n.)	
7	asignar_grupos	clasifica A/B/C (config. classify_species) sobre conteos post-thinning ; C se marca pero no se descarta.	V4: recalcular sobre conteos de Sudamérica (cambia el set modelable).
8	_reportar_por_especie + guardar	tabla inicial→final por especie y escribe el .gpkg.	

Detalle del paso 3b (filtro Sudamérica). Dos métodos posibles — verifiqué contra el dataset que dan **exactamente los mismos 8.498 registros** (coincidencia 100%, 0 discrepancias):

- **por geometría:** punto dentro del polígono / bbox de Sudamérica (config.PREDICTION_BBBOX).
- **por país:** columna país $\in$ {Chile, Colombia, Bolivia, Perú, Argentina, Brasil, Ecuador, Paraguay, ...}.

Decisión A — método del filtro 3b. Recomendando **por geometría** (el resto del pipeline es coordenada-dependiente y es robusto ante etiquetas de país ausentes/erróneas). "Por país" es igual de válido hoy. → *Determina cómo escribo el paso 3b.*

Efecto del paso 7 en V4 (set de especies modelables). Ampliar a Sudamérica suma candidatas que con "solo Chile" quedaban fuera: **Nolana albescens** (365 reg. en SA), posiblemente **Dinemagonum gayanum** (65) y **Nolana rostrata** (60); y da más datos a *Schinus areira* (72 → 1.135 crudos). *Atriplex semibaccata* sigue bajo el piso de 50 (48 en SA). El grupo A/B/C debe recalcularse sobre SA post-thinning, no heredarse.

Verificación de salida (checklist de auditoría): 0 registros fuera de SA · 0 lat/lon NaN · 0 en océano · ≤ 1 punto por celda/especie · grupos recalculados · tabla inicial→final.

[02] 02_capas_presente.py — capas WorldClim (presente)

Salida: data/raw/worldclim_present/ (10 bioclim + elevación + land_mask.tif).

#	Paso	Qué hace	V4
1	Descargar ZIPs	WorldClim v2.1 bioclim 2.5' + elevación, con reanudación; extrae TIFs.	
2	Seleccionar bioclim	extrae/renombra las 10 de config.BIOCLIM_VARS (wc2.1_2.5m_bio_N.tif → bioN.tif).	
3	Preparar elevación	renombra a elevation.tif.	
4	Máscara de tierra	rasteriza Natural Earth sobre la grilla de bio1 → land_mask.tif.	
5	Verificar alineación	mismo extent/resolución/CRS en todas las capas.	

V4: WorldClim se descarga global; el recorte a Sudamérica ocurre aguas abajo. Sin cambio funcional (opcional: recortar al bbox SA para acelerar 03/04).

[03] 03_terrain.py — terreno y alineación de predictoras

Salida: data/processed/rasters_aligned/ (14 predictoras alineadas).

#	Paso	Qué hace	V4
1	Verificar entradas	exige elevación, mask y las 10 bioclim.	
2	Cargar elevación	elevation.tif.	
3	Derivar slope + aspect	xarray-spatial / richdem / Horn geográfico (escala metros por latitud — corrige el bug histórico).	
4	Descomponer aspecto	northness = cos(aspect), eastness = sin(aspect).	
5	Alinear bioclim	las 10 al grid de bio1 (grilla canónica).	
6	Alinear topográficas	elevación, slope, northness, eastness al mismo grid.	
7	Aplicar land mask	enmascara todas las capas.	
8	Verificar + escribir	verifica alineación y escribe los 14 GeoTIFF.	

V4: sin cambio funcional. La topografía no depende del alcance geográfico.

[04] 04_extraccion.py — dataset modelable por especie

Salida: data/processed/species_datasets/{slug}.parquet (+ _predictors.json). main() prepara el contexto y process_species() arma el dataset de cada especie.

‘main()’:

#	Paso	Qué hace	V4
m1	Especies modelables	lee columna grupo (A/B) del gpkg limpio (post-thinning).	hereda el set ampliado de [01].
m2	Cargar ocurrencias + abrir rasters + land_mask	prepara entradas.	
m3	‘_load_calibration_mask’	intersecta tierra ∩ Chile (polígono NE; respaldo CALIBRATION_BBOX).	V4: cambiar área de calibración a Sudamérica .

‘process_species()’:

#	Paso	Qué hace	V4
1	Filtrar presencias	registros de la especie.	
2	Extraer predictoras en presencias	+ descarta NaN + recorta presencias al área de calibración.	V4: recorta a SA (no a Chile).
3	Generar background	N_BACKGROUND=20.000 puntos dentro del área de calibración (target-group o aleatorio).	V4: background dentro de SA.
4	Selección de predictoras	elimina colineales: $ r > 0.7$ y VIF > 10 (sobre presencias).	
5	Combinar	presencias + background.	
6	Folds CV espacial	clustering adaptativo k-means (N_CV_FOLDS=5) garantizando presencias por fold.	
7	Guardar	ordena columnas → .parquet + _predictors.json.	

Decisión B — área de calibración (pasos m3/2/3). Recomiendo **calibrar en toda Sudamérica** (coherente con el alcance). Alternativa: seguir en Chile (pero entonces limpiar a SA aporta poco). → *No bloquea [01]; condiciona [04].*

[05] 05_modelado.py — ensemble (GLM·GAM·RF·GBM·MaxEnt)

Salida: data/modeling/ensemble_models/{slug}.joblib (+ {slug}_cv_preds.parquet). Pasos de process_species():

#	Paso	Qué hace	V4
1	Cargar datos	.parquet + _predictors.json.	
2	Ajustar scaler	StandardScaler sobre los predictores.	
3	Construir modelos	5 algoritmos con hiperparámetros de tuned_params/*.json.	
4	Spatial CV	leave-one-block-out → TSS y AUC por algoritmo y por fold.	
5	Pesos del ensemble	equal-weight ; excluye algoritmos con TSS<0.5.	
6	Reentrenar	todos los modelos con el 100% de los datos.	
7	Umbrales	maxTSS, p10, min_train sobre las predicciones de training.	
8	OOF del ensemble	predicción out-of-fold ponderada (norm. por fila) → cv_preds.parquet.	
9	Serializar	guarda el artefacto joblib (incluye train_env para MESS).	

V4: sin cambio de lógica. Los números cambiarán al cambiar el área de calibración en [04].

[06] 06_validacion.py — métricas

Salida: outputs/tables/metrics_{slug}.csv + metrics_all.csv. Pasos de validate_species():

#	Paso	Qué hace	V4
1	Cargar datos + artefacto	parquet, predictoras, joblib (umbrales guardados).	
2	Cargar OOF (cv_preds)	base de las métricas; si no hay, usa training con warning .	
3	Umbral	usa el maxTSS fijado en entrenamiento (no se re-optimiza sobre OOF).	(corrección 3.1 ya aplicada — mantener).
4	Discriminación	TSS, AUC-ROC, AUC-PR, F1.	
5	Calibración	Brier, slope/intercept + figura <code>calib_*.png</code> .	
6	Solo-presencia	Boyce/CBI , OR10.	
7	Robustez espacial	TSS y AUC media ± SD por fold ← número de encabezado honesto.	
8	Ensemble	SD entre algoritmos, acuerdo binario.	
9	Extrapolación	MESS, % de área extrapolada.	
10	Exportar	<code>metrics_{slug}.csv</code> + consolidado <code>metrics_all.csv</code> .	

[07b] 07b_present_suitability.py — idoneidad presente

Salida: `outputs/maps/{slug}_present_suitability.tif`.

#	Paso	Qué hace	V4
1	Especies modelables	grupo A/B del gpkg.	
2	Cargar bioclim presente + topo	entradas de predicción.	
3	project_present por especie	<code>build_predictor_stack</code> (recorta a <code>PREDICTION_BBOX = Sudamérica</code>) → <code>predict_ensemble</code> → <code>reconstruct_raster</code> → <code>save_geotiff</code> .	<code>PREDICTION_BBOX</code> ya es Sudamérica.

[07] 07_forecast_2050.py — proyección 2050 (DIFERIDO, no certificado)

Pasos de `process_species()`: (1) cargar ensemble · (2) descargar CMIP6 (4 GCM × 2 SSP) · (3) proyectar presente · (4) proyectar cada GCM×SSP · (5) ensemble de ensembles (mean+SD) + Δidoneidad · (6) MESS futuro · (7) tabla de áreas (Mollweide).

Estado: rasters calculados en `outputs/maps/_forecast_deferred/`, **no certificados** (falta MESS Chile→SA y validación por hindcasting). Fuera del alcance inmediato de V4.

[08] `08_mapas.py` — figuras

Salida: `outputs/figures/*.png`. Por especie: idoneidad presente, mapas binarios (`maxTSS/p10/min_train`), panel comparativo presente vs 2050, incertidumbre del ensemble, MESS, y curva de calibración. **Vista centrada en Sudamérica** (no global).

Decisiones de auditoría abiertas

- **A — método del filtro Sudamérica (paso [01].3b):** geometría (recomendado) vs país.
- **B — área de calibración / background → RESUELTA.** El background NO es ni Chile fijo

ni todo Sudamérica, sino el **área accesible (M) por especie**: buffer de 300 km alrededor de las presencias de cada especie $\cap$ tierra-SA (distancia geodésica exacta, BallTree-haversine, `src/extraccion/background.py::muestrear_background_especie`). Evita el desajuste `presencia(SA)/fondo(Chile)` sin caer en la inflación trivial de un fondo continental para endémicas estrictas. Implementado en `05_entrenar_ensemble.py` y `07_predecir_sudamerica.py`.